

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ
Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»
Факультет Программной Инженерии и Компьютерной Техники

ЛАБОРАТОРНАЯ РАБОТА №2
по дисциплине
«Культура ИИ: Квалифицированный заказчик»

Работу выполнил:
Студент группы Р4100
Болорболд Аригуун

Преподаватель:
Двойникова Анастасия Александровна

г. Санкт-Петербург
2026

Содержание

1. Текст задания	3
2. Выполнение	4
2.1. Источники данных	4
2.2. Сравнение источников данных	4
2.3. Выбор лучшего источника	6
2.4. Паспорт датасета	6
2.5. Уточнение описания полей	7
2.6. Проверка пригодности для импорта	8
2.7. Аналитические гипотезы	8
3. Вывод	8

1. Текст задания

Выберите тему, связанную с вашей программой или интересом.

1. Найдите 3 источника данных.
2. Сравните их по владельцу, дате обновления, лицензии, формату, пригодности и рискам.
3. Выберите 1 лучший источник.
4. Оформите паспорт датасета.

Домашнее продолжение: уточнить описание полей, проверить пригодность для импорта и сформулировать 2-3 аналитические гипотезы.

Сдача: один файл PDF. Имя файла — Фамилия_Группа_ЛР2. Включите в него датасета в человекочитаемом виде. Исходный JSON преобразуйте в аккуратно оформленный документ, для конвертации можно использовать LLM.

2. Выполнение

2.1. Источники данных

Для анализа выбрана тема автоматической детекции спама в комментариях к видео на YouTube — задача релевантна модерации пользовательского контента.

1. **Zenodo (DOI 10.5281/zenodo.4533301)** — «Dataset of Video Comments of a Vision Video Classified by Their Relevance, Polarity, Intention, and Topic», TIB / Leibniz University Hannover.
2. **Kaggle** — ноутбук ahmedhassansaqr «youtube-comments-spam-detection-fl-score-96», входные данные во вкладке Input.
3. **UCI ML Repository, 380** — «YouTube Spam Collection», T.C. Alberto & J.V. Lochter (2015).

Этих я выбрал, так как я всегда интересовался вопросом о том, почему YouTube перешёл на использование ИИ для модерации комментариев, и почему человеческие модераторы востребованы всё реже и реже. Как пользователь платформы, модерация не достигает необходимого стандарта, так как злонамеренные лица находят лазейки для обхода новых (и не таких частых) улучшений для детекции спама. Нередко я узнаю о случаях, где через комменты эти же лица распространяют каналы Discord с нелегальными контентом, а также о неудовлетворительной работе модерации в отношении целенаправленной и массовой кампании ненависти от индивидуальных троллей (через человек и ботов) и даже правительственных лиц.

2.2. Сравнение источников данных

Критерий	Источник 1 Zenodo (zenodo.4533301)	Источник 2 Kaggle-ноутбук	Источник 3 UCI ML Repository 380
Владелец	TIB – Leibniz Information Centre for Science and Technology / Leibniz University Hannover (исследовате-	Пользователь Kaggle (ahmedhassansaqr); первоисточник данных – T.C. Alberto, J.V. Lochter (UFSCar, Бразилия)	T.C. Alberto, J.V. Lochter; хостится UCI Machine Learning Repository

	льская группа по Requirements Engineering)		
Дата обновления	v1 – начало 2021; v2.0 – 7 июня 2021	Дата загрузки на Kaggle не зафиксирована явно на странице кода – нужно проверить вручную	Донирован в репозиторий 25.03.2017 (сами комментарии собраны раньше, ок. 2013–2015)
Лицензия	CC BY 4.0 (стандарт для Zenodo-депозитов этой группы)	Не указана отдельно на странице ноутбука – наследуется от исходного датасета, но это не гарантировано	CC BY 4.0 (указана официально на странице датасета)
Формат	1 файл Dataset.xlsx: сырые + размеченные комментарии и ответы	CSV (согласно исходной структуре UCI)	5 CSV-файлов (по одному на видео), 1956 записей, 3 признака
Пригодность	4400 комментариев, размечены вручную по релевантности (ham/spam), тональности, намерению, теме – узкоспециализированная разметка под	Дублирует источник 3 по содержанию – добавляет мало нового, если использовать оба	Классический, хорошо документированный бенчмарк для задачи детекции спама, есть готовый Python-пакет <code>ucimlrepo</code> для загрузки

	RE, не «спам» в привычном смысле		
Риски	Только 1 видео – плохая обобщаемость; 126 комментариев и 26 ответов без даты (NULL); субъективность разметки 3 ассессоров	Вторичный источник – нет гарантии полноты/актуальности копии; юридический статус лицензии менее ясен	Данные 2013 года – спам-техники с тех пор сильно изменились; только 5 популярных музыкальных клипов – узкая предметная область

2.3. Выбор лучшего источника

Источником для дальнейшей работы выбран **UCI ML Repository 380 (YouTube Spam Collection)**.

Обоснование: датасет имеет однозначную открытую лицензию (CC BY 4.0), официальную DOI-регистрацию и воспроизводимую загрузку через пакет `usimlrepo`, что снижает риски при импорте и цитировании. Источник 2 (Kaggle) содержит, по всей видимости, копию этих же данных без чёткой лицензии и провенанса — использование его отдельно добавляет юридическую неопределённость без новой информации. Источник 1 (Zenodo) содержит качественную, но узкоспециализированную разметку (relevances для requirements engineering, а не спам в привычном смысле) и охватывает всего одно видео, что плохо подходит именно под задачу детекции спама.

2.4. Паспорт датасета

Исходный JSON:

```
{
  "dataset_name": "YouTube Spam Collection",
  "source_url": "https://archive.ics.uci.edu/dataset/380/youtube+spam+collection",
  "doi": "10.24432/C58885",
  "owner": "T.C. Alberto, J.V. Lochter (UFSCar, Brazil)",
  "hosting_repository": "UCI Machine Learning Repository",
  "publication_date": "collected ~2013-2015; donated 2017-03-25",
```

```

"license": "CC BY 4.0",
"format": "CSV, 5 files (one per video)",
"volume": "1956 instances total, 3 base fields + class label",
"collection_period": "comments to 5 most-viewed music videos on
YouTube (Psy, Katy Perry, LMFAO, Eminem, Shakira)",
"schema": ["COMMENT_ID", "AUTHOR", "DATE", "CONTENT", "CLASS"],
"target_variable": "CLASS (1 = spam, 0 = ham)",
"known_limitations": [
    "только 5 видео, все музыкальные клипы -- узкая предметная
область",
    "данные собраны в 2013-2015, паттерны спама с тех пор
изменились",
    "часть значений DATE может отсутствовать/быть некорректной"
]
}

```

Человекочитаемая версия:

Поле	Значение
Название	YouTube Spam Collection
Источник	UCI ML Repository, https://archive.ics.uci.edu/dataset/380/
DOI	10.24432/C58885
Владелец	T.C. Alberto, J.V. Lochter (UFSCar, Бразилия)
Дата публикации	собиран 2013–2015, донирован 25.03.2017
Лицензия	CC BY 4.0
Формат	CSV, 5 файлов (по одному на видео)
Объём	1956 записей, 3 базовых поля + метка класса
Период сбора	комментарии к 5 самым просматриваемым музыкальным клипам
Схема	COMMENT_ID, AUTHOR, DATE, CONTENT, CLASS
Целевая переменная	CLASS (1 = спам, 0 = не спам)

2.5. Уточнение описания полей

- **COMMENT_ID** — уникальный идентификатор комментария (строка).
- **AUTHOR** — имя пользователя, оставившего комментарий (строка).
- **DATE** — дата и время публикации комментария (timestamp; часть значений отсутствует).

- **CONTENT** — текст комментария (строка, часто содержит ссылки, эмодзи, спецсимволы).
- **CLASS** — бинарная метка: 1 — спам, 0 — не спам (int).

2.6. Проверка пригодности для импорта

Датасет открывается без ошибок через `pandas.read_csv()` для каждого из 5 файлов, либо целиком через официальный пакет `ucimlrepo` (`fetch_ucirepo(id=380)`). Пропущенных значений в базовых полях не зафиксировано. Кодировка UTF-8, возможны эмодзи и не-латинские символы в **CONTENT** — при обработке текста стоит явно указать `encoding="utf-8"`. Поле **CLASS** уже приведено к типу `int` и готово для использования как целевая переменная без дополнительного маппинга.

2.7. Аналитические гипотезы

1. Комментарии, содержащие URL-ссылки или слова-триггеры («subscribe», «channel», «check out»), статистически значимо чаще помечены как спам (**CLASS** = 1), чем комментарии без таких признаков.
2. Средняя длина комментария (число слов) статистически различается между классами `spam` и `ham` — спам-комментарии в среднем короче и более шаблонны.
3. Доля спам-комментариев различается в зависимости от видео (Avril Lavigne, Kendrick Lamar, Drake, Eminem, JPEGMafia) — то есть популярность/аудитория видео влияет на уровень спама сильнее, чем содержание самого комментария.

3. Вывод

В ходе работы было рассмотрено три источника данных, тематически связанных с комментариями к видео на YouTube: узкоспециализированный академический датасет с Zenodo (разметка для requirements engineering), вторичное Kaggle-зеркало и первичный источник — UCI ML Repository 380 (YouTube Spam Collection). Сравнение по владельцу, дате обновления, лицензии, формату, пригодности и рискам показало, что источник с UCI наиболее пригоден под задачу автоматической детекции спама: у него чёткая открытая лицензия (CC BY 4.0), официальная DOI-регистрация и воспроизводимый способ загрузки, тогда как Kaggle-источник дублирует те же данные без ясного первоисточника, а Zenodo-датасет решает похожую, однако иную задачу.

Проверка пригодности для импорта подтвердила, что датасет открывается без ошибок и не требует предварительной очистки для использования в задаче классификации. Сформулированные гипотезы

(связь спама со ссылками/триггерными словами, различие в длине комментариев между классами, зависимость доли спама от конкретного видео) задают направления для дальнейшего анализа и построения классификатора.

Таким образом, цель задания — выбрать и паспортизировать один датасет под конкретную аналитическую задачу — достигнута:

- обоснован выбор источника,
- описана его структура,
- намечены проверяемые направления анализа.