

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ
Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»
Факультет Программной Инженерии и Компьютерной Техники

ЛАБОРАТОРНАЯ РАБОТА №3
по дисциплине
«Культура ИИ: Квалифицированный заказчик»

Работу выполнил:
Студент группы Р4100
Болорболд Аригуун

Преподаватель:
Двойникова Анастасия Александровна

г. Санкт-Петербург
2026

Содержание

1. Текст задания	3
2. Декларация об использовании ИИ и технологий, поддерживаемых ИИ ..	4
3. Выполнение	5
3.1. Какие проблемы были в данных	5
3.2. Какие действия по очистке были выполнены	5
3.3. Ключевые метрики до очистки	5
3.4. Ключевые метрики после очистки	5
3.5. Что стало лучше после очистки	6
3.6. Что осталось под вопросом	6
4. Вывод	6

1. Текст задания

1. Выберите формат данных: CSV, JSON или XML.
2. Найдите пропуски, дубликаты, выбросы и непоследовательные категории.
3. Опишите решения по очистке.
4. Сравните данные до и после: количество строк, пропуски, дубликаты, среднее или медиану выбранного числового поля, минимум или максимум.
5. Сдайте очищенный файл и отчёт «До / После».

Сдача: один файл PDF и очищенный файл выбранного формата (CSV, JSON или XML). Имя файла — Фамилия_Группа_ЛР3.

2. Декларация об использовании ИИ и технологий, поддерживаемых ИИ

При подготовке этой работы не была использована никакая модель ИИ в любой степени. Я принимаю на себя полную ответственность за содержание итогового отчета.

3. Выполнение

3.1. Какие проблемы были в данных

1. Много пропусков: больше всего в «last_promotion_date» (60%), затем «team_size» и «phone»; только 1508 из 11500 строк были полностью заполнены;
2. Дубликаты по employee_id и по паре ФИО + email. В phone вместо NaN стояла текстовая заглушка «некорректный номер»;
3. Выбросы в зарплатах, особенно в маркетинге, производстве и R&D.

3.2. Какие действия по очистке были выполнены

1. Удалён столбец с долей пропусков > 30% (last_promotion_date);
2. Удалены строки, где пропущено > 50% столбцов, и строки без критических полей (employee_id, full_name, department, position, salary);
3. «Некорректный номер» заменён на NaN. Пропуски заполнены: зарплата — медианой по должности и городу, бонус — через медианную долю от зарплаты по отделу, остальные числовые — средним или медианой в зависимости от асимметрии, категориальные — модой, даты — 1900-01-01;
4. Дубликаты по ФИО + email удалены с сохранением записи с самой ранней датой найма.

3.3. Ключевые метрики до очистки

Строк: 11500;
пропуски: 19009;
некорректные номера телефона: 159;
повторы ID: 1500;
повторы фамилии + почт: 3790;
выбросы: 427;
среднее salary: 228202,1;
медиана: 181000

3.4. Ключевые метрики после очистки

Строк: 7281;
пропуски: 0;
некорректные номера телефона: 159;
повторы ID: 84;
повторы фамилии + почт: 0;
выбросы: 258;

среднее salary: 245678,3;
медиана: 202000

3.5. Что стало лучше после очистки

1. В данных не осталось пропусков и дубляжей сотрудников;
2. Число строк соответствует реальному числу уникальных людей;
3. По таблице можно считать средние по отделам и строить графики без искажений.

3.6. Что осталось под вопросом

Заполненные значения оценочные, особенно доли бонусов и стаж. Дата 1900-01-01 в датах — условная заглушка, её нужно исключать из любых расчётов по времени. Выбросы в зарплатах не удалялись (могут быть реальными руководящими ставками), поэтому в метрике «после» они остались. Дубликаты определялись по ФИО + email, и люди (у которых одинаковая фамилия) с одинаковой почтой могли быть удалены ошибочно.

4. Вывод

В ходе работы я прошёл полный цикл очистки данных на двух наборах: данных сотрудников (11500 строк, 20 столбцов) и городских сервисных заявок. В обоих случаях исходные данные содержали пропуски, дубликаты и выбросы, а в данных сотрудников ещё и текстовую заглушку «некорректный номер» вместо стандартного NaN.

Простое удаление всех строк с пропусками уничтожило бы около 87% данных сотрудников, поэтому я использовал комбинацию методов: удаление столбца с наибольшей долей пропусков, удаление строк без критически важных полей и заполнение остальных пропусков с учётом типа данных и группы (например, зарплата по должности и городу). Дубликаты удалялись по ключевым атрибутам, а при выборе записи учитывалась дата найма.

Главный вывод: способ очистки напрямую влияет на результат анализа, и однозначно «правильного» способа нет. Часть решений (заполнение медианой, порог в 120 часов, дата-заглушка 1900-01-01) эвристические, и в реальной задаче их стоило бы согласовывать с владельцем данных.

Очищенные наборы сохранены в файлы

lesson03_cleaned_employee_data.csv и

lesson03_cleaned_city_services.csv, но в рамке данного задания было принято решение выложить только первую из них.